

Annotation de séquence : mitogénomes

Contexte : suite au séquençage d'un génome eucaryote complet, vous avez obtenu un contig qui correspond à la séquence (brute) du génome mitochondrial.

1. Rechercher ce qu'est un Contig

Un contig (abréviation de contiguous sequence) est une séquence d'ADN continue et ordonnée, reconstituée à partir de fragments plus courts issus du séquençage. Ces fragments sont ensuite assemblés, à l'aide d'algorithmes bioinformatiques, en séquences plus longues grâce aux chevauchements entre les fragments. Ces séquences reconstruites sont appelées contigs.

Dans ce contexte, le contig correspond à une portion reconstituée du génome mitochondrial, qui représente une séquence brute, c'est-à-dire non annotée ni interprétée.

2. Etant donné que la séquence est mitochondriale, quels sont les différents types de gènes attendus ? seront-ils morcelés ?

Les gènes attendus sont des gènes codant pour des protéines (notamment impliquées dans la chaîne respiratoire), des gènes codant pour des ARN ribosomiques et des gènes codant pour des ARN de transfert (nécessaires à la traduction des protéines mitochondriales).

Morcelés

3. Dans un premier temps, utilisez l'outil TRANSLATE TOOLS (expasy) pour rechercher les cadres ouverts de lecture.

A quoi correspondent les séquences surlignées en rouge ? Les séquences surlignées en rouge correspondent à des Open Reading Frames (ORF), autrement dit des cadres de lecture ouvert. Cela correspond à un segment du cadre de lecture susceptible d'être transcrit en ARN messager pour être traduit en protéine ou en peptide. Un ORF comporte un codon d'initiation et se termine par un codon STOP.

Faites un commentaire sur le nombre de CDS **PUTATIVES** identifiées. Expasy nous permet de voir tous les ORFs possibles dans plusieurs sens de lecture. Ces ORFs ont des tailles diverses allant de 3 ou 4 nucléotides à une centaine. Un ORF long sans codon STOP intermédiaire est typique d'une séquence codante. En effet, plus l'ORF est long plus il est probable qu'il code pour une protéine fonctionnelle, car les protéines ont besoin d'une certaine longueur pour assurer une fonction biologique. C'est pour cela que nous considérons les ORFs les plus longs comme des CDS putatives. Par rapport à la quantité d'ORFs identifiés, la proportion de CDS putatives est moindre. Pour le premier cadre de lecture 5'3', nous pouvons identifier 5 CDS putatives, sans assurer qu'elles soient réellement des séquences codantes.

Quelle observation pouvez-vous faire quant au début des CDS **PUTATIVES** identifiées ?

Nous remarquons que les CDS putatives les plus longues correspondent à des protéines.

Comment pouvez-vous savoir si elles correspondent effectivement à des protéines mitochondriales ? Vous pouvez cliquer sur les liens disponibles.

En cliquant sur le codon d'initiation d'une CDS putative, nous sommes dirigés vers Prosite, un logiciel qui permet de vérifier si la séquence choisie est bien traduite en protéine ou non.

4. Une façon plus directe d'annoter une telle séquence est d'utiliser un logiciel dédié disponible sur le serveur Galaxy (<https://usegalaxy.eu>). Créer vous d'abord un compte qui servira aussi pour le BMB3. Puis caractériser le génome à l'aide du logiciel MITOS2. Vous indiquerez les paramètres choisis, présenterez vos résultats.

Genetic code *

Invertebrate (5) ▼

(--code)

Reference data *

RefSeq63 Metazoa ▼

Contact the administrator of this Galaxy instance if you miss reference data (--refseqver)

Treat sequence as linear

☐ No

(--linear)

Outputs - optional


BED x mito x GFF file x SEQ x nucleotide FASTA x protein FASTA x geneorder x

Protein prediction plot x Missing genes x

Les paramètres utilisés dans MITOS2 ont été choisis afin d'optimiser l'annotation d'un génome mitochondrial d'invertébré. Le code génétique "Invertebrate (5)" a été sélectionné car il correspond au code de traduction mitochondrial propre aux invertébrés. La base de données de référence RefSeq63 Metazoa a été utilisée pour garantir une annotation de haute qualité dérivés de génomes mitochondriaux métazoaires bien caractérisés. L'option "Treat sequence as linear" a été désactivée (mode circulaire), car les génomes mitochondriaux sont majoritairement circulaires chez les invertébrés, ce qui permet à l'outil de rechercher des gènes à cheval sur l'origine ou la fin de la séquence. Les sorties sélectionnées (BED, mito, gene order, etc...) permettent une analyse complète incluant la prédiction des CDS, l'ordre des gènes, et la vérification visuelle des régions potentiellement non annotées ou manquantes.

Ordre des gènes :


```
>mitochondrion_complete_genome
cox1 trnS2 trnA trnY trnT_1 nad5 trnH cox3 trnQ nad4l nad4 trnS1 nad2 trnF trnW atp6 cob trnI trnK trnM rrnS trnR trnE trnG trnV trnP
nad6 nad3 trnD trnN trnC cox2 rrnL trnL2 nad1 trnT_0
```




L'analyse du *protein prediction plot* généré par MITOS2 met en évidence la présence de plusieurs régions codantes bien définies réparties sur l'ensemble du génome mitochondrial étudié. Chaque courbe colorée représente une CDS putative identifiée par le logiciel en s'appuyant sur la base de référence *RefSeq63 Metazoa*. La hauteur et l'épaisseur des courbes correspondent à la qualité de la prédiction, c'est-à-dire à la probabilité que la séquence soit effectivement traduite en protéine. On observe des pics larges et de haute qualité pour la majorité des gènes mitochondriaux typiques, notamment *cox1*, *cox2*, *cox3*, *cob*, *nad1*, *nad2*, *nad3*, *nad4*, *nad4l*, *nad5*, *nad6*, et *atp6*, suggérant qu'ils sont très probablement traduits. Au total, 13 protéines codantes typiques du génome mitochondrial des métazoaires ont été identifiées avec une forte probabilité de traduction, ce qui est cohérent avec l'organisation des génomes mitochondriaux d'invertébrés. Quelques zones de faible signal pourraient correspondre à des ORFs partiels, très divergents ou à des artefacts, mais elles ne remettent pas en question la qualité générale de l'annotation. Ces résultats confirment que le génome analysé est complet et biologiquement fonctionnel.

Le tableau 1 proposé en pièce jointe correspond à l'annotation complète du génome mitochondrial. Nous y retrouvons notamment les gènes codants identifiés dans l'ordre sur la séquence, leur position exacte, le type de gène et le brin sur lequel il est transcrit.


5. Pour identifier les éventuelles régions répétées, utiliser le logiciel DOTTUP.




Word size : 40
Zoom 9500-10500 nucléotides



Word size : 60
Zoom 9700-10200 nucléotides



Word size : 10
Séquence entière



Word size : 20
Séquence entière

Pour identifier d'éventuelles régions répétées dans le génome mitochondrial, nous avons utilisé le logiciel DOTTUP, qui génère un dot plot représentant les correspondances exactes entre segments de la séquence. Nous avons testé plusieurs tailles de mot (*word size*) afin d'ajuster la sensibilité de la détection. Sur le graphique en haut à gauche (word size = 10), de nombreux points très dispersés apparaissent. Cela révèle une très forte sensibilité mais génère aussi beaucoup de bruit, rendant l'interprétation difficile. À word size = 20, seules les correspondances les plus longues et significatives sont conservées, ce qui réduit le bruit tout en conservant une bonne visibilité des répétitions. Un zoom plus précis a été effectué entre 9500 et 10500 nucléotides, avec un word size = 40 puis 60. Pour réaliser ces zooms sur la séquence, j'ai regardé sur les premiers plots obtenus vers quelle position de nucléotides se trouvait les séquences répétées (lignes parallèles à la diagonale autour du 10 000 ème nucléotide). J'ai ensuite copié la séquence sur Brackets qui est un éditeur de texte, pour déterminer avec précision sur quelles lignes se trouve le 9500 ème nucléotide et le 10500 ème afin d'encadrer les séquences répétées sans les couper du plot. Ces paramètres plus stricts permettent d'isoler clairement des motifs répétés. Sur le dernier graphique, au word size=60 et avec le zoom le plus restreint, les doubles traits parallèles visibles de part et d'autre de la diagonale principale correspondent à des répétitions directes situées à différentes positions mais de même orientation, et indiquent probablement une duplication d'une séquence située dans cette région. Ces répétitions pourraient correspondre à des éléments structuraux du génome mitochondrial, comme des duplications de gènes ou des séquences régulatrices répétées.

RepeatID	Repeat position	Size	GC (%)	Sequence
1	9726-9790; 9964-10028	65	38.5	AAAATTTGTTGGTCTGGTGTGTTTGGCGTGCGAAAAATTTTAAAGAAGGAGCATTAAATATCGGG
2	9824-9909; 9943-10028	86	37.2	CAAATGTTGCATTGGACATTAATAATTTGTGGGTCTGGTGTGTTTGGCGTGCGAAAAATTTTAAAGAAGGAGCATTAAATATCGGG
3	9726-9820; 9845-9939	95	34.7	AAAATTTGTTGGTCTGGTGTGTTTGGCGTGCGAAAAATTTTAAAGAAGGAGCATTAAATATCGGGCGAATTTTAAAGTTAAGGATTAGATAGAG
RepeatID	Repeat position	Size	GC (%)	Sequence

L'analyse de la séquence mitochondriale d'Atrina avec RepFinder a permis d'identifier trois séquences répétées de taille modérée, comprises entre 65 et 95 nucléotides. Ces répétitions présentent un pourcentage de GC relativement faible, ce qui est cohérent avec la composition typique des génomes mitochondriaux riches en A et T. La présence de telles répétitions peut avoir plusieurs implications : elles peuvent jouer un rôle dans la régulation de la réplication ou de la transcription du génome

mitochondrial, ou encore être le résultat de duplications récentes. Leur taille modeste et leur faible complexité génétique suggèrent également qu'elles pourraient être situées dans des régions non codantes, servant potentiellement de structures secondaires ou de sites de recombinaison.

6. Enfin, identifiez à quelle espèce appartient ce génome mitochondrial ?

Select all 100 sequences selected		GenBank	Graphics	Distance tree of results	MISA viewer				
	Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
☒	Atrina pectinata mitochondrion, complete genome	Atrina pectinata	30845	31806	100%	0.0	100.00%	16703	ON193523.1
☒	Atrina pectinata mitochondrion, complete genome	Atrina pectinata	15127	31568	100%	0.0	99.45%	16811	NC_020028.1
☒	Atrina pectinata mitochondrial COI gene for cytochrome c oxidase subunit I, partial cds	Atrina pectinata	1640	1640	5%	0.0	99.78%	894	AB076914.1

BLASTN avec les paramètres par défaut. -> *Atrina pectinata* mitochondrion


Les indicateurs du BLAST indiquent que la séquence de l'exercice provient très probablement de la banque car 100% d'identité et 100% de couverture. La séquence correspond au génome mitochondrial de l'espèce *Atrina pectinata*

7. Répéter l'analyse avec la séquence MN432488.1 et analyser les différences structurales entre les 2 mitogénomes, en particulier les réarrangements de gènes sur le génome par une analyse de **synténie** (chercher sur Galaxy le logiciel qui vous permet de le faire).

Nous avons finalement utilisé la séquence NC_060781.1 correspondant à *Pinna rudis*.


Ordre des gènes :

>NC_060781.1
cox2 trnI trnF trnD nad6 trnR nad3 trnN trnM rrnS trnG trnH rrnL trnL2 nad1 trnL1 trnQ nad4l nad4 nad5 trnS1 nad2 trnY trnT cox1 cox3 trnS2 trnA trnW atp6 cob




Le protein prediction plot de cette seconde séquence mitochondriale montre des pics de probabilité de traduction pour plusieurs gènes, notamment *cox1*, *cob*, *cox3*, *nad2*, *nad4*, *nad5*, *nad6* et *atp6*, avec des valeurs de densité atteignant ou dépassant 10^2 , ce qui indique une forte probabilité que ces segments soient effectivement traduits. Ces gènes présentent une densité de signal sur des régions étendues, renforçant l'hypothèse de leur expression effective. On peut estimer ici qu'au moins 11 protéines sont très probablement traduites, en se basant sur la présence de larges plateaux de densité élevée au niveau des ORFs correspondants. Comparé au premier génome analysé, cette séquence montre une meilleure continuité et netteté des signaux, suggérant une annotation plus propre ou une meilleure qualité de la séquence d'entrée. Les signaux sont bien distincts les uns des autres, sans chevauchement majeur, ce qui facilite l'interprétation.


Le tableau 2 proposé en pièce jointe correspond à l'annotation complète du génome mitochondrial. Nous y retrouvons notamment les gènes codants identifiés dans l'ordre sur la séquence, leur position exacte, le type de gène et le brin sur lequel il est transcrit.



Word size : 10
Séquence entière



Word size : 40
Zoom 3600-4500 nucléotides



Word size : 60
Zoom 3600-4500 nucléotides

L'analyse obtenue via DOTTUP avec différents word sizes révèle ici aussi la présence de régions répétées. Avec un word size de 10, on observe une densité importante de points sur la diagonale ainsi que quelques lignes secondaires, signe de reprises locales ou motifs répétés. En augmentant la taille à 40 puis 60 et en zoomant sur la séquence, des doubles traits parallèles deviennent visibles. Ceux-ci indiquent des répétitions directes, où une séquence est copiée à un autre endroit du génome avec la même orientation. Ces motifs sont particulièrement nets et réguliers, ce qui suggère qu'il s'agit de véritables duplications plutôt que de simples coïncidences. En comparaison avec la première séquence, les motifs répétés sont ici plus courts et moins nombreux, mais mieux localisés. La zone répétée détectée ne semble pas coïncider avec les gènes majeurs d'après le protein prediction plot, ce qui pourrait indiquer qu'il s'agit d'éléments régulateurs ou de séquences non codantes dupliquées.

RepeatID	Repeat position	Size	GC (%)	Sequence
1	3855-3998; 4058-4201	144	43.1	GGGGAAAAATCTTGTAGGAGCTAAAAAAGTTCAAGAGCCTAAAAAATTTTGGGGCCTAGCGAGGTTGGGGTAAGATTTTGTGTTTGGTTTGGGA
RepeatID	Repeat position	Size	GC (%)	Sequence

Pour la séquence mitochondriale de *Pinna*, l'analyse avec RepFinder a révélé une séquence répétée unique de 144 nucléotides avec un taux de GC de 43,1 %. Cette répétition, plus longue et légèrement plus riche en GC que celles observées chez *Atrina*, pourrait refléter une région fonctionnelle particulière du génome ou un événement de duplication spécifique à cette espèce.


Tableau 1 : Tableau comparatif des deux mitogénomes

Critère	<i>Atrina pectinata</i>	<i>Pinna rudis</i>
Organisme	<i>Atrina pectinata</i> (mollusque bivalve)	<i>Pinna rudis</i> (mollusque bivalve)
Taille du génome	16 703 pb	18264 pb
Nombre de CDS annotées	13 protéines codantes (MITOS2)	12 protéines codantes (référence NCBI)
Nombre de tRNA	animaux)	22
Présence d'ARNr	Oui	Oui
Séquences répétées détectées	3 répétitions imbriquées	1 répétition isolée
Localisation des répétitions	Positions 9726–10028 (zone dense)	Positions 3855–4201
%GC des répétitions	34,7 % à 38,5 %	43,10%
Région de contrôle (D-loop)	Non précisée, possible chevauchement	D-loop identifiée à l'extrémité
Protéines traduites	13 ORF traduites (courbes claires sur plot)	13 ORF traduites (signal net)
Organisation générale	locales (répétitions)	Standard et plus linéaire
visibles (Dottup)	Oui, motifs répétitifs visibles	Non, structure plus simple

Le tableau 3 d'ordre des gènes en pièce jointe permet l'analyse comparative des ordres géniques des deux mitogénomes qui révèle à la fois des similitudes structurelles importantes et des différences notables. Tous les gènes codant pour les protéines et les ARN ribosomiques sont présents dans les deux génomes, ce qui reflète une conservation fonctionnelle typique des génomes mitochondriaux. Cependant, l'ordre des gènes varie de manière significative : par exemple, le gène *cox1* est en première position chez *Atrina*, tandis qu'il se retrouve en 25^e position chez *Pinna*. Cette réorganisation suggère des événements de réarrangements mitochondriaux, courants chez les mollusques, tels que des inversions ou des transpositions. Les ARN de transfert sont particulièrement sujets à ces réarrangements ; certains comme *trnK* et *trnE* sont absents de *Pinna* alors qu'ils sont présents chez *Atrina*, tandis que *trnL1*, absent chez *Atrina*, est retrouvé chez *Pinna*.

Malgré ces différences d'organisation, la présence conservée de la majorité des gènes témoigne d'une pression évolutive forte sur la conservation de la fonction mitochondriale, même si leur position dans le génome peut varier. L'analyse met en évidence des zones de synténie partielle interrompues par des inversions ou des insertions. Le fait que les gènes comme *atp6*, *cob*, *nad1*, ou encore *cox3* soient présents dans les deux séquences avec des positions très différentes peut s'expliquer par une évolution indépendante des régions intergéniques, favorisée par des mécanismes de recombinaison ou de dérive génétique. Enfin, l'absence ou la variation dans la position de certains tRNAs peut aussi résulter d'une annotation difficile.

8. Donnez pour les deux mitogénomes des représentations graphiques, circulaires des génomes.




```

File "/Library/Frameworks/Python.framework/Versions/3.12/lib/python3.12/site-packages/Bio/SeqIO/Interfaces.py", line 81, in __init__
    self.stream = open(source, "r" + mode)
    ^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^
FileNotFoundError: [Errno 2] No such file or directory: '/Macintosh_HD/Utilisateurs/didine/Bureau/pinnacox1.fasta'
>>> import os
>>> print(os.path.exists("pinnacox1.fasta"))
False
>>> exit()
didine@Air-de-didine ~ % ls/Users/didine/Desktop/pinnacox1.fasta
zsh: no such file or directory: ls/Users/didine/Desktop/pinnacox1.fasta
didine@Air-de-didine ~ % python3
Python 3.12.10 (v3.12.10:0cc81280367, Apr 8 2025, 08:46:59) [Clang 13.0.0 (clang-1300.0.29.30)] on darwin
Type "help", "copyright", "credits" or "license" for more information.
>>> from Bio import SeqIO
>>> from Bio.SeqRecord import SeqRecord
>>> from Bio.SeqFeature import SeqFeature, FeatureLocation
>>> record = SeqIO.read("/Users/didine/Desktop/pinnacox1.fasta", "fasta")
/Library/Frameworks/Python.framework/Versions/3.12/lib/python3.12/site-packages/Bio/SeqIO/FastaIO.py:203: BiopythonDeprecationWarning: Previously, the FASTA parser silently
ignored comments at the beginning of the FASTA file (before the first sequence).

Nowadays, the FASTA file format is usually understood not to have any such comments, and most software packages do not allow them. Therefore, the use of comments at the beg
inning of a FASTA file is now deprecated in Biopython.

In a future Biopython release, this deprecation warning will be replaced by a ValueError. To avoid this, there are three options:

(1) Modify your FASTA file to remove such comments at the beginning of the file.

(2) Use SeqIO.parse with the 'fasta-pearson' format instead of 'fasta'. This format is consistent with the FASTA format defined by William Pearson's FASTA aligner software.
This format allows for comments before the first sequence; lines starting with the ';' character anywhere in the file are also regarded as comment lines and are ignored.

(3) Use the 'fasta-blast' format. This format regards any lines starting with '!', '#', or ';' as comment lines. The 'fasta-blast' format may be safer than the 'fasta-pears
on' format, as it explicitly indicates which lines are comments.
warnings.warn(
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
    File "/Library/Frameworks/Python.framework/Versions/3.12/lib/python3.12/site-packages/Bio/SeqIO/__init__.py", line 691, in read
        raise ValueError("No records found in handle") from None
ValueError: No records found in handle
>>> record = SeqIO.read("/Users/didine/Desktop/pinnacox1.fasta", "fasta")
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
    File "/Library/Frameworks/Python.framework/Versions/3.12/lib/python3.12/site-packages/Bio/SeqIO/__init__.py", line 691, in read
        raise ValueError("No records found in handle") from None
ValueError: No records found in handle
>>> █

```

Afin de réaliser une comparaison plus pertinente des deux mitogénomes, j'ai modifié la séquence de *Pinna rudis* pour qu'elle débute par le même gène que celle d'*Atrina pectinata*, *Cox1*. J'ai ensuite tenté de convertir mon nouveau fichier FASTA au format GenBank grâce à Biopython mais cela n'a pas fonctionné. L'analyse n'est donc pas optimale.