

Amandine ARLIAUD TP1 BMB3

Pauline BONNE TP2 BMB3

2025 – 2026. TP Techniques omiques BMB3

Vous travaillerez sur des séquences génomiques de microsporidie *Encephalitozoon intestinalis*. Les données sont accessibles sur le NCBI sous les numéros d'accès suivants :

- pour le génome référence : GCA_000146465,
- pour les données SRA : SRX19810871, SRX19810872 et SRX19810873.

Partie I. Récupérer des séquences.

Afin de différencier plus facilement les différentes données SRA, nous les avons renommées par les deux derniers chiffres de leur code séquence SRR donc, 14, 15 et 16.

1. Commentez les données du génome référence.

Le génome de référence de *Encephalitozoon intestinalis* présente une taille totale de 2,2 Mb, ce qui est extrêmement réduit pour un organisme eucaryote. La taille très réduite du génome s'explique par son mode de vie parasite intracellulaire obligatoire : de nombreuses fonctions métaboliques sont prises en charge par la cellule hôte, ce qui entraîne une perte de gènes non essentiels et une forte réduction génomique au cours de l'évolution.

Le génome est composé de 11 chromosomes, correspondant également à 11 scaffolds, ce qui suggère une très bonne continuité de l'assemblage. L'absence de fragmentation importante est confirmée par le faible nombre de contigs (12 contigs au total).

Les indicateurs de qualité de l'assemblage sont élevés, le N50 atteint 196,6 kb, avec un L50 de 6, ce qui reflète une très bonne continuité des séquences sans gaps.

La longueur totale non gapée est équivalente à la taille totale du génome (2,2 Mb), ce qui indique une absence ou quasi-absence de régions indéterminées (N) dans l'assemblage. Cela renforce la fiabilité de la séquence de référence pour des analyses bioinformatiques ultérieures.

2. Commentez les données SRA

Les données SRA sont trois isolats distincts d'*Encephalitozoon intestinalis*. Elles correspondent à des données de séquençage haut débit (NGS) par la plateforme Illumina. Les reads ont été séquencés en paired-end de 151 bp. Les Phred score de chaque isolat est supérieure à 30 ce qui indique une faible probabilité d'erreur d'appel des bases. Cette bonne qualité de séquençage limite la génération de faux positifs lors de l'identification des SNPs et garantit la robustesse des analyses réalisées par la suite.

3. Quelles sont les tailles des fichiers ?

Le fichier du génome de référence au format fasta mesure 2 193 Ko. Le fichier au format fastq de l'échantillon 14 mesure 2 860 878 Ko, pour l'échantillon 15 2 604 422 Ko et pour l'échantillon 16 3 200 685 Ko.

Partie II. Contrôle qualité des reads Illumina

4. Réalisez le contrôle qualité des reads avec fastqc (installez le sur votre pc). L'analyse doit prendre 2 minutes.
5. Commentez vos résultats indiquez votre démarche pour améliorer la qualité des reads.

Un contrôle de qualité des lectures de séquençage a été réalisé à l'aide du logiciel FastQC afin d'évaluer la fiabilité des données SRA avant l'analyse des variants. Cette étape permet notamment d'examiner la distribution des scores de qualité Phred le long des reads, la présence éventuelle de séquences adaptatrices, ainsi que la composition en bases. Lorsque des anomalies sont détectées, comme une baisse de la qualité en fin de lecture ou la présence de séquences techniques résiduelles, une étape de pré-traitement des reads est nécessaire pour améliorer la qualité globale des données.

L'amélioration de la qualité des reads repose principalement sur le trimming, qui consiste à supprimer les bases de mauvaise qualité en extrémité des reads, ainsi que sur le retrait des séquences adaptatrices pouvant interférer avec l'alignement sur le génome de référence. Cette étape peut être réalisée à l'aide d'outils dédiés tels que Trimmomatic. Un filtrage des reads trop courts ou présentant une qualité moyenne insuffisante peut également être appliqué. Ces traitements permettent de réduire le bruit lié aux erreurs de séquençage et de limiter la détection de faux variants.

Nous allons maintenant passer à l'interprétation des fastQC pour les 3 reads. Tout d'abord, nous pouvons constater qu'ils révèlent des profils de qualité similaire car nous avons obtenu pour les 3 reads, les résultats suivants :

- basic statistics
- per base sequence quality
- per sequence quality scores
- per base sequence content
- per sequence GC content
- per base N content
- sequence length distribution
- sequence duplication levels
- overrepresented sequences
- adapter content

C'est pourquoi l'interprétation des graphiques suivants sera la même pour les 3 SRA car nous avons obtenu les mêmes graphiques pour SRA 14, 15, 16.

Interprétation du fastQC




figure 1 : Per base sequence quality

Ce graphique nous permet d'observer la qualité moyenne des bases le long du read avec en abscisse la position dans le read et en ordonnée le Phred score. On retrouve 2 courbes : en rouge la médiane et en bleu la moyenne. Pour les deux courbes, nous sommes aux alentours de 30 sur toute la longueur, ce qui indique une très bonne fiabilité des bases. En effet, nous n'observons pas de chute brutale du score de Phred en fin de read (3'), ce qui indique et confirme une très bonne qualité du read.




Figure 2 : per sequence quality scores

Ce graphique reflète la qualité moyenne par read, avec en abscisse le score de Phred et en ordonnée le nombre de reads. Ici, on observe un pic net autour de 29 (Phred score) ce qui correspond à une probabilité d'erreur de 0,1%. On a donc une excellente fiabilité des bases.




Figure 3 : Per base sequence content

Ce graphique révèle la proportion de A, T, C, G à chaque position du read avec en abscisse la position dans le read et en ordonnée le pourcentage de chaque nucléotide. Sur ce graphe, on peut observer 4 courbes, représentant les 4 bases, avec une allure assez spéciale. En effet, au début du read et jusqu'à 15 pb, les bases sont désordonnées montrant un déséquilibre. Puis, après 15pb, les courbes se stabilisent, on obtient deux lignes horizontales bien distinctes. On a A-T aux alentours de 30% et G-C aux alentours de 20%, (cela montre que le reads possèdent plus de A, T que de G, C. Pour conclure, malgré un déséquilibre au début du read, on observe une stabilisation de la composition nucléotidique montrant une bonne qualité. Néanmoins, afin d'optimiser et améliorer la qualité du read, il faudrait réaliser un trimming, c'est-à-dire supprimer les bases de mauvaises qualités au début du read.





Figure 4 : Per sequence GC content

Ce graphique montre la distribution des bases GC par read avec en abscisse le % de GC et en ordonnée le nombre de read. Ici, on retrouve deux courbes :

- bleu : distribution théorique, sert de référence
- violet : distribution réel

On peut voir que la courbe violette est très similaire à la courbe bleue. En effet, elles suivent pratiquement la même allure avec un pic aux alentours de 40% pour les deux courbes. Cela signifie que la proportion des bases GC obtenue (réelle) correspond à celle attendue. On a donc ici une parfaite distribution des bases GC.



Le graphique montre la répartition de la longueur des reads avec en abscisse la longueur de la séquence (pb) et en ordonnée le nombre des reads. Ici, on observe une longueur de reads homogènes. En effet, on a une distribution sous forme triangulaire ciblée entre 150 et 152 pb signifiant que la plupart des reads sont entre 150 et 152 pb.

(ici, l'allure du graphique était la même pour les 3 reads, en revanche, il n'y avait pas le même nombre de reads :

- SRA 14 : 7 000 000
- SRA 15 : 6 000 000
- SRA 16 : 8 000 000)

! Overrepresented sequences

Sequence	Count	Percentage	Possible Source
GGG	9196	0.12017528131940854	No Hit

Figure 6 : SRA 14

! Overrepresented sequences

Sequence	Count	Percentage	Possible Source
GGG	8658	0.12424888121474018	No Hit

Figure 7 : SRA 15

[illegible]

Figure 8 : SRA 16

Ces données montrent que pour les 3 reads, nous avons des séquences anormalement répétées. En effet, fastQC regarde les reads et met un signal d'alerte lorsque une séquence apparaît "trop souvent". Cela peut être dû à la présence d'adaptateurs Illumina.

Conclusion :

Les reads présentent une très bonne qualité globale. Un trimming peut néanmoins être effectué en début de reads afin d'améliorer et corriger le déséquilibre au niveau de la composition des bases.

Partie III. Alignement des reads des trois isolats contre la référence.

- Alignez les reads illumina « trimmés » de chaque isolat sur le génome référence en utilisant le logiciel bwa. Attention le dossier fastq contient les paired-end reads. Utilisez l'option -p.
- Combien de reads sont-ils mappés ?

Après alignement des reads contre le génome de référence de *Encephalitozoon intestinalis* à l'aide de l'outil BWA, le nombre de reads mappés obtenus est le suivant :

14 : 6 950 007 reads mappés

15 : 6 241 777 reads mappés

16 : 7 426 912 reads mappés

Ces valeurs élevées indiquent que la majorité des reads s'alignent correctement sur le génome de référence, ce qui témoigne d'une bonne qualité des données de séquençage et d'une forte similarité entre les reads et le génome de référence utilisé.

Les différences observées entre les trois échantillons peuvent s'expliquer par des variations de profondeur de séquençage, de qualité des reads ou de préparation des bibliothèques, et ne sont pas inhabituelles dans des données issues de séquençage haut débit.


Étant donné la petite taille du génome de *E. intestinalis*, ces nombres élevés de reads mappés suggèrent malgré tout une couverture importante du génome, favorable à des analyses fiables (détection de variants, expression génique, etc.).

Globalement, le fort nombre de reads mappés confirme que le génome de référence est adapté pour l'alignement et que les données SRA sont exploitables pour des analyses ultérieures, telles que l'étude de la couverture génomique ou de l'expression des gènes.

8. Combien y a-t-il de FLAG 4, 16, 144 ? (idéalement vous pouvez représenter la fréquence de chaque FLAG. Il est possible de copier la colonne 2 dans un autre fichier avec la commande `cut -f2 le_fichier > new_file.tsv`)

Code FLAG	4	16	144
14	706 951	3 490 647	1 744 657
15	730 890	3 133 914	1 566 303
16	1 135 945	3 729 124	1 863 435

9. Filtrez les reads et générez les fichiers d'alignements (.bam) indexés (.bam.bai)
10. Visualisez l'alignement des reads des trois isolats simultanément sur le chromosome du génome de référence qui correspond au N₅₀. Faites une capture d'écran.



Après avoir généré les fichiers bam et bam.bai (indexation), nous nous sommes rendus sur IGV et avons placé le génome de référence en format fasta. Nous avons ensuite ajouté les 3 isolats et les avons observés sur le chromosome 6 du génome de référence, correspondant au N₅₀ (= longueur du contig le plus petit qui partage la séquence en 2). C'est -à -dire que la moitié du génome total est contenue dans des chromosomes supérieurs ou égaux à la taille du chromosome 6. (chromosome 6 : 89 212 - 108 484 kb)

On retrouve donc le génome de référence, les 3 isolats (SRR 14, 15, 16) alignés sur le chromosome 6 du génome de référence. On observe aussi les reads avec les bases colorées (A, T, C, G) correspondant aux différences observées par rapport au génome de référence. (Ce que IGV met en couleurs/en évidence, correspond aux différences observées avec le génome de référence).

Si on regarde les 3 isolats, on peut voir à plusieurs endroits des blocs rouges. Ces blocs correspondent aux indels : insertion (présence de bases supplémentaires par rapport au génome), délétion (absence de base par rapport au génome de référence). Certains blocs sont présents au même endroit dans plusieurs isolats, ce n'est donc probablement pas une erreur de séquençage mais bien une variation réelle par rapport au génome de référence ou bien que

l'indel est conservé entre les isolats. En revanche, lorsqu'on observe des blocs présents dans 1 isolat, on parle de variation spécifique.

On retrouve aussi des endroits où on observe des traits fins, colorés et présents parfois dans les 3 isolats et au même endroit. Cela correspond aux SNPs (= Single Nucleotide Polymorphisms). Pareil pour ici, dans le cas où le SNPs est retrouvé dans les 3 isolats, on ne considère pas cela comme une erreur de séquençage. Cela reflète seulement le polymorphisme réel par rapport au génome de référence.

Pour conclure, on observe un polymorphisme modéré par rapport au génome de référence. En effet, des indels et SNPs sont présents simultanément dans les 3 isolats au même endroit ce qui montre que ces modifications sont conservées. Cela reflète également une forte similarité entre les 3 échantillons.

Partie IV. Générer un fichier de variant génétique.

11. Générez un fichier vcf (non compressé) des variants génétiques uniquement. Les trois isolats doivent être dans le même fichier.

Commande utilisée :

```
bcftools mpileup -f genomic_ref.fasta 14.bam 15.bam 16.bam | \bcftools call -mv -Ov -o variants_3_isolats.vcf
```

Pour cette commande nous avons utilisé le génome de référence au format fasta et nos données SRA au format bam. Le fichier de sortie était variants_3_isolats.vcf

12. Comptez les SNP et les INDELS.

Commande pour les SNP :

```
bcftools view -v snps variants_3_isolats.vcf | bcftools view -H | wc -l
```

Commande pour les INDELS :

```
bcftools view -v indels variants_3_isolats.vcf | bcftools view -H | wc -l
```

Grâce à ces commandes, nous avons pu compter 531 mutations par SNP et 36 mutations par INDELS.

13. Triez les SNP et INDELS dans deux fichiers distincts.


Commande pour le fichier SNP :

```
bcftools view -v snps variants_3_isolats.vcf -Ov -o variants_3_isolats_SNP.vcf
```

Commande pour le fichier INDELS :

```
bcftools view -v indels variants_3_isolats.vcf -Ov -o variants_3_isolats_INDEL.vcf
```


14. A partir du manuel d'utilisation de vcftools, trouvez une commande qui vous permet de calculer la densité de SNP pour 5 kb et Pi pour 5 kb. Représentez graphiquement vos résultats.



Les graphiques représentent la densité de SNP et la diversité nucléotidique (Pi) calculées par fenêtres de 5 kb sur l'ensemble du génome d'*Encephalitozoon intestinalis*. L'utilisation de fenêtres glissantes permet d'analyser la distribution de la diversité génétique de manière locale tout en couvrant l'intégralité du génome assemblé. Le calcul de la densité de SNP permet d'identifier les régions du génome où les mutations s'accumulent, sans tenir compte de leur fréquence. La diversité nucléotidique (Pi) apporte une information complémentaire en intégrant la fréquence des variants et la diversité réelle entre les séquences. L'association de ces deux

indicateurs permet de distinguer les régions contenant des SNP rares de celles présentant une diversité génétique significative.

Le graphique de densité de SNP montre que le nombre de polymorphismes par fenêtre de 5 kb est globalement très faible sur la majorité du génome. Cette observation est cohérente avec les caractéristiques biologiques des microsporidies, qui possèdent des génomes extrêmement compacts, peu redondants et soumis à de fortes contraintes évolutives. La faible densité de SNP suggère une forte conservation des séquences, probablement liée à un mode de vie parasitaire intracellulaire, limitant la tolérance aux mutations. Toutefois, certaines fenêtres présentent des pics ponctuels de densité de SNP, principalement localisés dans certaines régions du génome. Ces variations peuvent refléter des zones moins contraintes fonctionnellement, des régions intergéniques, ou encore des différences locales de couverture de séquençage pouvant influencer la détection des variants.

Le graphique de diversité nucléotidique (Pi) confirme cette tendance globale à une faible diversité génétique. Les valeurs de Pi sont proches de zéro sur une grande partie du génome, indiquant une homogénéité élevée entre les séquences analysées. Cette faible diversité est compatible avec une reproduction majoritairement clonale et une pression de sélection élevée, caractéristiques des parasites obligatoires. Néanmoins, des augmentations locales de Pi sont observées dans certaines fenêtres, souvent en concordance avec les pics de densité de SNP. Ces régions correspondent à des zones où les polymorphismes détectés sont non seulement plus nombreux, mais aussi plus fréquemment partagés entre les individus étudiés.

En conclusion, l'analyse met en évidence une diversité génétique globalement faible, avec quelques régions localisées présentant une variabilité plus élevée. Ces résultats sont cohérents avec les contraintes évolutives fortes qui s'exercent sur le génome des microsporidies. Le calcul combiné de la densité de SNP et de la diversité nucléotidique constitue une approche essentielle pour caractériser la structure de la diversité génétique et mieux comprendre l'organisation et l'évolution du génome de ce parasite.

Partie V. Annoter le génome.

Nous n'avons pas pu réaliser cette partie car le logiciel gffread ne pouvait pas exploiter nos données issues de BRAKER.

15. A l'aide de BRAKER accessible sur le serveur Galaxy, générez un fichier GFF et/ou GTF. Vous spécifierez les options choisies ?
16. Installez gffread (ou cufflinks) sur vos ordinateurs et générez les fichiers fasta de cds supérieurs à 300 nt, et des protéines correspondantes. Pour connaître les modalités d'utilisation de gffread, tapez `gffread -h` dans votre terminal. Avec ces paramètres, combien trouvez-vous de gènes ?
17. Annotez vos cds en utilisant NCBI Blast sur le serveur Galaxy.

Si gffread avait fonctionné, pour l'annotation fonctionnelle des CDS prédits, il aurait été préférable d'utiliser BLASTp plutôt que BLASTn. En effet, BLASTp compare des séquences protéiques, qui sont généralement plus conservées au cours de l'évolution que les séquences nucléotidiques. Cela permet d'identifier plus facilement des homologues fonctionnels, même lorsque les séquences d'ADN présentent de nombreuses substitutions synonymes. De plus, l'annotation des génomes repose principalement sur la similarité avec des protéines déjà caractérisées, ce qui rend BLASTp plus pertinent pour attribuer une fonction aux gènes prédits.