

Compte-rendu TP Techniques omiques

Introduction

La transcriptomique est une discipline de la biologie moléculaire qui s'intéresse à l'ensemble des ARN messagers produits par une cellule ou un organisme à un moment donné, appelé transcriptome. L'étude du transcriptome permet de comprendre comment l'expression des gènes varie en fonction des conditions biologiques, génétiques ou environnementales. Parmi les approches modernes de transcriptomique, la technique RNA-seq (RNA sequencing) occupe une place centrale. Elle repose sur le séquençage à haut débit des ARN convertis en ADN complémentaire, puis sur une analyse bioinformatique permettant d'aligner ces séquences sur un génome de référence et de quantifier l'expression des gènes.

Dans ce TP, nous avons travaillé sur un jeu de données RNA-seq issu de la levure *Saccharomyces cerevisiae*. L'objectif principal était de comparer l'expression génique entre deux conditions biologiques : une souche sauvage (WT pour "wild type") et une condition impliquant le facteur de transcription RAP1. RAP1 est une protéine connue pour jouer un rôle important dans la régulation de l'expression de nombreux gènes, notamment ceux liés à la structure de la chromatine et au métabolisme cellulaire.

Ainsi, ce TP avait pour but de découvrir les principales étapes d'une analyse transcriptomique, depuis les données brutes jusqu'à l'identification de gènes différentiellement exprimés, en utilisant des outils bioinformatiques sous RStudio.

Résumé de l'expérience

L'expérience s'inscrit dans une étude transcriptomique visant à analyser l'impact du facteur de transcription Rap1 sur l'expression génique chez la levure *Saccharomyces cerevisiae*. Pour cela, deux conditions biologiques ont été comparées : une condition sauvage (WT), dans laquelle Rap1 est normalement exprimé et fonctionnel, et une condition expérimentale (RAP1), obtenue à partir d'une souche génétiquement modifiée permettant la dégradation conditionnelle de Rap1. Le déroulement global de cette expérience est synthétisé dans le schéma présenté ci-dessous, qui reprend les principales étapes du protocole, depuis la culture des levures jusqu'à l'analyse bioinformatique des données RNA-seq.




Figure 1: Schéma de l'expérience

Dans la condition RAP1, la protéine Rap1 a été marquée par un système de dégradation induit par l'auxine (système AID). L'ajout d'auxine au milieu de culture entraîne sa dégradation rapide et permet d'étudier les conséquences de sa perte de fonction. Pour chacune des deux conditions, l'ARN a été extrait, puis utilisé pour réaliser un séquençage RNA-seq. Les reads obtenus ont été alignés sur le génome de référence de la levure et comptés par gène. Les données ont ensuite été analysées avec DESeq2 afin d'identifier les gènes différentiellement exprimés entre WT et RAP1. Enfin, les résultats ont été visualisés à l'aide d'une PCA, d'un volcano plot et d'une heatmap.

Méthodologie Bio-informatique

L'analyse bioinformatique réalisée au cours de ce TP a suivi les grandes étapes classiques d'un pipeline RNA-seq, allant de la récupération des données brutes jusqu'à l'analyse statistique de l'expression différentielle. L'ensemble du traitement a été effectué sous RStudio, en combinant des commandes en ligne de commande (Terminal) et des scripts R utilisant des packages spécialisés en bioinformatique.

La première étape a consisté à récupérer les données de séquençage sous forme de fichiers FASTQ compressés (.fastq.gz). Ces fichiers contiennent les reads issus du séquençage haut débit de l'ARN après rétro-transcription en ADN complémentaire. Chaque read est décrit par quatre lignes : un identifiant unique, la séquence nucléotidique, une ligne séparatrice, puis une ligne de scores de qualité associés à chaque base (scores Phred). Ces scores permettent d'évaluer la fiabilité du séquençage pour chaque nucléotide. L'exploration des premières lignes du fichier FASTQ a permis de vérifier la structure correcte des données et de confirmer qu'il s'agissait bien de séquences issues d'ARN-seq.

Parallèlement à ces données brutes, un fichier d'annotation au format GTF (Gene Transfer Format) a été téléchargé. Ce fichier joue un rôle essentiel dans l'analyse transcriptomique car il décrit la localisation précise des gènes, des exons et des transcrits sur le génome de référence de la levure. Chaque ligne du GTF correspond à un élément génomique annoté (gène, exon, CDS, etc.) et contient des informations sur le chromosome, la position de début et de fin, le brin, ainsi que des identifiants de gènes et de transcrits. Dans le cadre de l'analyse RNA-seq, ce fichier sert de référence pour associer les reads alignés à des gènes spécifiques lors de l'étape de comptage.

L'étape suivante a été l'installation du génome de référence de *Saccharomyces cerevisiae* au format FASTA. Ce fichier contient l'intégralité des séquences nucléotidiques des chromosomes de la levure. Avant de pouvoir aligner les reads sur ce génome, il a été nécessaire de construire un index génomique à l'aide du package Rsubread. Cette indexation consiste à organiser le génome de manière optimisée pour permettre une recherche rapide des positions correspondant aux reads. Sans cette étape, l'alignement serait beaucoup plus lent et moins efficace.

Une fois l'index créé, chaque fichier FASTQ a été aligné individuellement sur le génome de référence à l'aide de la fonction `Rsubread::align`. Cette étape transforme les reads bruts en fichiers BAM, qui contiennent les mêmes séquences mais désormais positionnées précisément sur le génome. L'alignement permet de déterminer d'où provient chaque read dans le génome et donc à quel gène il correspond potentiellement. Les statistiques d'alignement ont montré qu'une grande majorité des reads étaient correctement mappés, ce qui atteste de la bonne qualité des données et de la pertinence du génome de référence utilisé.

Après l'alignement, les fichiers BAM ont été utilisés pour quantifier l'expression des gènes grâce au package `featureCounts` (également inclus dans Rsubread). Cette étape consiste à compter combien de reads s'alignent sur les exons de chaque gène, en utilisant le fichier GTF comme guide d'annotation. Le résultat est une matrice de comptages où chaque ligne correspond à un gène et chaque colonne à un échantillon RNA-seq. Ces comptages représentent une estimation brute de l'abondance des transcrits pour chaque gène dans chaque condition.

Cependant, ces données brutes ne sont pas directement comparables entre échantillons, car elles peuvent être influencées par des différences techniques telles que la profondeur de séquençage ou l'efficacité de la préparation des bibliothèques. Pour corriger ces biais, l'analyse différentielle a été réalisée avec le package DESeq2. Ce logiciel normalise les comptages en tenant compte des variations techniques entre échantillons, puis applique un modèle statistique basé sur une distribution binomiale négative pour tester si les différences observées entre WT et RAP1 sont significatives. DESeq2 fournit pour chaque gène plusieurs données clés : le log2FoldChange, qui mesure l'amplitude du changement d'expression entre les deux conditions, ainsi qu'une p-value ajustée (padj) qui tient compte des tests multiples. Ces critères ont permis de classer les gènes en trois catégories : non significatifs, sur-exprimés ou sous-exprimés en condition RAP1 par rapport à WT. Enfin, des analyses exploratoires et graphiques ont été réalisées sur les données transformées, notamment une transformation de stabilisation de variance (VST) pour permettre une comparaison visuelle des échantillons. Ces données ont servi de base à la réalisation d'une PCA, d'un volcano plot et d'une heatmap, permettant d'interpréter globalement et visuellement l'impact de RAP1 sur le transcriptome.

Résultats




Figure 2: PCA plot des échantillons WT et RAP1

L'analyse en composantes principales (PCA) a été réalisée à partir des données normalisées par transformation de stabilisation de variance (VST) afin de comparer globalement les profils d'expression des différents échantillons. Chaque point du graphique représente un échantillon RNA-seq, projeté dans un espace réduit à deux dimensions correspondant aux deux premières composantes principales (PC1 et PC2), qui résument l'essentiel de la variabilité des données.

Sur le graphique obtenu, l'axe PC1 explique la plus grande part de la variation entre échantillons et correspond majoritairement à la différence liée à la condition biologique (WT versus RAP1). L'axe PC2 représente une source secondaire de variation, probablement liée à des différences biologiques mineures entre réplicats ou à des variations techniques.

On observe une séparation nette entre les échantillons WT et RAP1 le long de l'axe PC1 : les trois réplicats WT se regroupent d'un côté du graphique, tandis que les trois réplicats RAP1 forment un second groupe distinct. Cette organisation indique que la condition RAP1 modifie fortement le transcriptome par rapport à la condition WT. De plus, le regroupement serré des réplicats au sein de chaque condition témoigne d'une bonne reproductibilité biologique et technique des données RNA-seq.

Dans l'ensemble, la PCA confirme que la condition biologique est le principal facteur expliquant les différences d'expression observées et valide la pertinence de poursuivre l'analyse différentielle entre WT et RAP1.




Figure 3: Volcano plot

Le volcano plot représente graphiquement les résultats de l'analyse différentielle réalisée avec DESeq2. En abscisse (axe x) figure le $\log_2\text{FoldChange}$, qui mesure l'ampleur du changement d'expression entre RAP1 et WT : des valeurs positives indiquent une sur-expression en RAP1, tandis que des valeurs négatives indiquent une sous-expression. En ordonnée (axe y) figure le $-\log_{10}$ de la p-value ajustée, qui reflète la significativité statistique des différences : plus un point est haut sur le graphique, plus le changement d'expression est statistiquement fiable.

Des seuils ont été matérialisés par des lignes pointillées : une ligne verticale correspondant à $|\log_2\text{FC}| = 0,5$ et une ligne horizontale correspondant à $\text{padj} = 0,1$. Les

gènes situés au-delà de ces seuils sont considérés comme significativement différentiellement exprimés.

Sur le graphique, la majorité des points se situe autour de $\log_2\text{FoldChange}$ proche de zéro et sous le seuil de significativité, ce qui signifie que la plupart des gènes ne sont pas fortement affectés par la condition RAP1. Toutefois, un nombre identifiable de gènes apparaît au-dessus du seuil horizontal : certains sont sur-exprimés en RAP1 (points à droite, colorés en rouge), tandis que d'autres sont sous-exprimés (points à gauche, colorés en bleu). Ces gènes constituent les candidats principaux potentiellement régulés par RAP1.

Lorsque les gènes significatifs sont annotés avec leurs noms, on peut identifier précisément lesquels sont les plus affectés. Cela permet de relier les changements d'expression à des fonctions biologiques spécifiques et d'émettre des hypothèses sur le rôle de RAP1 dans la régulation transcriptionnelle.

Globalement, le volcano plot montre que RAP1 n'affecte pas uniformément l'ensemble du transcriptome, mais régule plutôt un sous-ensemble spécifique de gènes, avec des effets parfois importants en termes de variation d'expression.




Figure 4: Heatmap des gènes significatifs

La heatmap a été construite uniquement à partir des gènes considérés comme significativement différentiellement exprimés ($\text{padj} < 0.1$ et $|\log_2\text{FC}| \geq 0.5$). Les données utilisées ne sont pas les comptages bruts mais les valeurs transformées par VST, ce qui permet une comparaison visuelle plus fiable entre échantillons.

Dans cette représentation, chaque ligne correspond à un gène et chaque colonne correspond à un échantillon RNA-seq. Les couleurs traduisent le niveau d'expression relatif : les teintes chaudes (rouge) indiquent une expression plus élevée que la moyenne pour ce gène, tandis que les teintes froides (bleu) indiquent une expression plus faible que la moyenne. Les valeurs sont centrées et mises à l'échelle par ligne, ce qui met en évidence les variations relatives entre conditions plutôt que les niveaux absolus.

L'analyse de clustering hiérarchique associée à la heatmap montre que les échantillons WT se regroupent ensemble et que les échantillons RAP1 forment un second groupe distinct. Cette séparation nette confirme les résultats observés en PCA et suggère que les deux conditions présentent des profils d'expression clairement différents.

Au niveau des gènes, le clustering révèle également des groupes de gènes ayant des comportements similaires : certains sont globalement plus exprimés en RAP1, tandis que d'autres sont préférentiellement exprimés en WT. Cela suggère que RAP1 agit comme un régulateur transcriptionnel, activant certains gènes et en réprimant d'autres.

Dans l'ensemble, la heatmap renforce l'idée que la perturbation de RAP1 entraîne une reprogrammation coordonnée de l'expression génique, plutôt qu'un effet aléatoire ou isolé sur quelques gènes.

Discussion

L'ensemble des résultats obtenus par PCA, volcano plot et heatmap montre que la déplétion conditionnelle de Rap1 entraîne une modification nette du transcriptome de *Saccharomyces cerevisiae*. La séparation claire des échantillons WT et RAP1 en PCA et sur la heatmap indique que Rap1 joue un rôle majeur dans la régulation globale de l'expression génique. Le volcano plot met en évidence un nombre limité mais significatif de gènes différentiellement exprimés, suggérant que Rap1 n'agit pas de manière diffuse sur l'ensemble du génome, mais cible préférentiellement certains loci. Parmi ces gènes, deux (YAR009C et YAR010C) apparaissent sous-exprimés en condition RAP1, tandis que YAL061W est sur-exprimé. Afin de caractériser biologiquement ces gènes, une recherche a été réalisée sur la base de données NCBI à l'aide de BLAST (blastn) et des fiches Gene/SGD associées : l'identifiant de chaque gène (par exemple YAR009C) a été entré dans BLAST, puis la fiche correspondante a été consultée pour identifier le transcrit (ARNm) et la protéine codée. Cette démarche a montré que YAR009C et YAR010C correspondent à des éléments de type rétrotransposon TY (protéines de type gag ou gag-pol), c'est-à-dire des séquences mobiles du génome plutôt que des gènes métaboliques classiques, ce qui suggère que la perte de Rap1 pourrait influencer la régulation ou la stabilité de ces éléments génomiques. À l'inverse, YAL061W (BDH2) code pour une probable alcool déshydrogénase impliquée dans des réactions d'oxydoréduction du métabolisme des alcools ; sa sur-expression en condition RAP1 pourrait traduire une réorientation métabolique ou une réponse compensatoire à la perturbation transcriptionnelle induite par la dégradation de Rap1. Dans l'ensemble, ces résultats sont cohérents avec l'idée que Rap1 agit à la fois comme activateur et répresseur de gènes et que sa perte entraîne une reprogrammation coordonnée de l'expression génique, en accord avec le modèle expérimental décrit dans l'article associé aux données.

Lien de l'article :

<https://www.sciencedirect.com/science/article/pii/S1097276518308785?via%3Dihub>